

PrediRuta - Sistema predictivo de riesgo vial basado en siniestralidad histórica y pronóstico climático

Reporte de implementación y experimentos

Fase 2 - Semanas 3, 4 y 5

Presentado por: Lizeth García, Carlos Silva y Leonardo Guzman

1. Resumen del avance

PrediRuta es un sistema clasificación y predicción de riesgo vial que estima la criticidad relativa de los tramos de una ruta dentro de Bogotá. La estimación combina los patrones históricos de siniestralidad con la ubicación y el momento previsto de tránsito. Las variables meteorológicas solo se incorporan al cálculo cuando demuestran un aporte predictivo suficiente. El resultado ofrece una lectura informativa del recorrido y no corresponde a una probabilidad individual de accidente, una recomendación de conducción ni una selección de rutas alternativas.

Durante las semanas 3, 4 y 5 se consolidó el proceso de preparación de la información. Las fuentes relacionales de la Secretaría Distrital de Movilidad se transformaron en seis tablas depuradas, se integró el clima histórico y se construyeron los conjuntos de datos requeridos para los tres objetivos analíticos. En cada objetivo se compararon regresión logística, Random Forest, XGBoost y MLP mediante validaciones temporales fuera de muestra y escenarios con y sin variables meteorológicas (Secretaría Distrital de Movilidad, s. f.).

Una red neuronal con variables climáticas fue seleccionada para construir la criticidad del MVP. En la validación de 2021 a 2023 obtuvo un ROC-AUC de 0,6234 y un F1 de 0,1781; en la prueba de 2024 a 2025 estas métricas fueron de 0,5981 y 0,1055 respectivamente. La disminución del F1 muestra que el desempeño es sensible al cambio de prevalencia. Por esta razón, la salida se interpreta como una medida de criticidad relativa a los datos históricos. El modelo de estado se conserva como análisis complementario, incluyendo variables de la persona y vehículo en el que se hará el traslado, se obtuvieron métricas aceptables y se está dando un valor adicional al usuario del planteado en el MVP. El modelo de clase no se incorpora al MVP de PrediRuta porque su desempeño no permite predecir de forma adecuada la categoría del accidente, especialmente en la clase OTROS.

La correspondencia entre el contenido desarrollado y los cuatro componentes exigidos para la entrega se resume en la Tabla 1.

Tabla 1. Cobertura de los criterios de la entrega de la fase 2.

Criterio de la entrega	Evidencia incluida	Estado al cierre de la revisión
Verificación de supuestos y tratamiento previo	Calidad, llaves, granularidad, alcance, faltantes, desbalance, fuga de información, correlación y cambio temporal.	Completado y documentado.

Criterio de la entrega	Evidencia incluida	Estado al cierre de la revisión
Calibración o entrenamiento	Variables, escenarios, particiones, modelos, hiperparámetros y métricas de los tres objetivos analíticos.	Completado y documentado.
Análisis de resultados y ajustes	Comparación con/sin clima, prueba temporal, sensibilidad aleatoria, errores por clase y decisión de uso.	Documentado; el clima no alcanza el umbral de mejora para la criticidad.
Plan de implementación	Actividades de semanas 6, 7 y 8, matriz de requisitos y criterios de aceptación.	Planificado; corresponde a trabajo posterior a esta entrega.

1.1. Estado integrado de los componentes

El estado del alcance, sus resultados utilizables y el trabajo previsto para la implementación se sintetizan en la Tabla 2. Como se observa, se cumplió con el plan de trabajo propuesto para estas tres semanas, además de incluir validación de modelos como el Estado del actor y la clase de accidente.

Tabla 2. Estado de los componentes analíticos y de datos.

Componente	Producto o resultado	Decisión	Estado
Limpieza y estructuración	Seis tablas relacionales depuradas; 895.346 accidentes finales.	Base histórica aceptada para modelado.	Completado.
Construcción de datasets	302.400 patrones; 895.346 eventos; 1.928.614 filas integradas.	Los productos corresponden a las unidades de análisis definidas.	Completado.
Ocurrencia	Comparación temporal de cuatro modelos con y sin clima; prueba futura y sensibilidad aleatoria.	XGBoost sin clima para criticidad relativa, con limitaciones de generalización documentadas.	Completado.
Estado del actor	Validación temporal, bootstrap, sensibilidad y artefactos exportados.	Análisis complementario, no entrada del MVP.	Completado.
Clase de accidente	Comparación temporal y análisis detallado por clase.	Análisis complementario, no entrada del MVP.	Completado.
Interfaz e integración	Diseño funcional definido en la primera entrega.	Implementación prevista en Streamlit.	Programado en el plan de implementación.

2. Alcance y fuentes de información

2.1. Alcance heredado de la primera entrega

El usuario objetivo es una persona que consulta un desplazamiento en automóvil o motocicleta dentro de Bogotá. Para realizar la consulta se ingresan el origen, el destino, la fecha y la hora de salida dentro de un horizonte de siete días calendario, incluido el día de la consulta, de acuerdo a la disponibilidad de OpenMeteo o Google Weather en variables

climáticas predecidas. A partir de esta información, el artefacto obtiene la ruta y los tiempos estimados por segmento, asigna cada punto a la unidad espacial correspondiente (teniendo en cuenta la clusterización empleada en la transformación de la data), calcula la criticidad para el momento previsto de tránsito y consulta el pronóstico meteorológico en puntos representativos. La salida presenta la ruta segmentada en los niveles Bajo, Medio y Alto, junto con la hora estimada de tránsito y las condiciones climáticas previstas.

El alcance conserva las exclusiones definidas en la primera entrega. PrediRuta no genera instrucciones de conducción, no recomienda rutas alternativas, no presenta una probabilidad individual de accidente y no establece relaciones causales entre el clima y la siniestralidad. Tampoco utiliza atributos personales de los actores viales para personalizar el resultado ni desarrolla modelos propios de clima o tráfico. Si las variables meteorológicas no mejoran al menos 5 % la métrica principal, el pronóstico se presenta como información contextual y no modifica la criticidad.

2.2. Usuarios directos, usuarios secundarios y actores interesados

Además del conductor que interactúa con el prototipo, PrediRuta puede generar valor para actores que estudian o gestionan la seguridad vial. Los usuarios directos y secundarios, junto con el uso esperado de la información, se diferencian en la Tabla 3 sin ampliar las funcionalidades comprometidas para el prototipo.

Tabla 3. Usuarios y actores interesados de PrediRuta.

Grupo	Necesidad o interés	Relación con el artefacto
Conductores de automóvil y motocicleta	Anticipar la criticidad relativa, el tiempo de tránsito y el clima de un recorrido.	Usuario directo del MVP mediante una consulta de origen, destino, fecha y hora.
Secretaría Distrital de Movilidad y equipos de seguridad vial	Reconocer patrones agregados por zona y momento para complementar el diagnóstico de siniestralidad.	Usuario secundario potencial de resultados agregados; no realiza seguimiento individual desde el MVP.
Entidades distritales y gestores de infraestructura vial	Contrastar sectores recurrentes con información de operación, señalización e infraestructura.	Actor interesado para análisis institucionales posteriores, sujeto a validación con otras fuentes.
Investigadores y comunidad académica	Reproducir el tratamiento de datos, evaluar los modelos y estudiar nuevas variables explicativas.	Usuario secundario de la documentación técnica y de resultados no personales.

2.3. Diseño analítico desarrollado

La separación entre los tres objetivos analíticos y sus respectivos conjuntos de datos se observa en la Figura 1.




Figura 1. Diseño de los tres modelos evaluados para PrediRuta. Fuente: elaboración propia.

Los tres objetivos se desarrollan por separado porque utilizan unidades de análisis diferentes. El modelo de ocurrencia trabaja con patrones espaciales y temporales; el modelo de clase utiliza una observación por accidente; y el modelo de estado utiliza una observación por actor vial. El análisis descriptivo permite revisar la calidad, la cobertura, la distribución y las relaciones presentes en los datos. El componente predictivo se concentra en estimar la ocurrencia relativa, mientras que los modelos de estado y clase se mantienen como análisis complementarios. No se desarrolla un componente prescriptivo, ya que el alcance excluye las recomendaciones de ruta y las instrucciones de conducción.

3. Captura de datos, limpieza y estructuración de la base

3.1. Inventario y función de las fuentes

El proceso parte de siete tablas históricas de la Secretaría Distrital de Movilidad. ACCIDENTE funciona como eje temporal y espacial, mientras que ACTOR_VIAL, VEHICULO, CAUSA y VIA aportan información complementaria sobre los involucrados y las condiciones del evento. LESIONADO y MUERTO se utilizan para validar el estado registrado de los actores, pero no se conservan como tablas finales porque esta información queda consolidada en ACTOR_VIAL. El volumen inicial y la función de cada fuente dentro del proceso de estructuración se detallan en la Tabla 4.

Tabla 4. Inventario de tablas originales de siniestralidad.

Fuente	Filas	Columnas	Función en la depuración
ACCIDENTE	904.476	23	Núcleo espacial, temporal, de clase y gravedad.
ACTOR_VIAL	3.273.697	15	Condición, estado, género y edad de los involucrados.
LESIONADO	481.423	19	Contraste de registros clasificados como heridos.
MUERTO	15.890	21	Contraste de registros clasificados como fallecidos.
VEHICULO	2.808.440	10	Clase y servicio de los vehículos.
CAUSA	1.870.450	11	Códigos, nombres y tipo de causa.
VIA	965.149	29	Características de infraestructura y vía representativa.

3.2. Verificaciones sobre ACCIDENTE

La depuración de ACCIDENTE inicia con la revisión de identificadores, formularios, fechas, horas y coordenadas. Los 904.476 registros cumplen las cinco validaciones estructurales, y los dos pares de coordenadas disponibles coinciden en todos los casos excepto uno. Posteriormente, el análisis se restringe al periodo comprendido desde 2007 y al perímetro urbano oficial de Bogotá. Los registros excluidos por estas dos condiciones quedan fuera del alcance definido para el proyecto, pero no se consideran errores de la fuente.

La evolución anual representada en la Figura 2 sustenta la selección temporal: desde 2007 la cobertura aumenta y se mantiene en decenas de miles de registros.




Figura 2. Número de accidentes por año y selección del periodo desde 2007. Fuente: elaboración propia.

El límite geográfico aplicado para restringir el análisis al área urbana de Bogotá se ilustra en la Figura 3.




Figura 3. Perímetro urbano oficial utilizado en la validación espacial. Fuente: elaboración propia con datos de la Secretaría Distrital de Planeación (s. f.).

El efecto acumulado de las reglas de calidad se cuantifica en la Tabla 5 y confirma el cumplimiento del umbral de 90 % definido en RD01.

Tabla 5. Resultados de calidad, periodo y alcance espacial de ACCIDENTE.

Prueba	Registros válidos	Porcentaje	Interpretación
ID, formulario, fecha, hora y coordenadas	904.476	100,00 %	Calidad estructural completa para las variables esenciales.
Fecha desde 2007	903.190	99,86 %	Se excluyen periodos con cobertura insuficiente.
Dentro del perímetro urbano	897.110	99,19 %	7.366 registros quedan fuera del alcance geográfico.
Calidad, periodo y perímetro	895.833	99,04 %	Conjunto elegible antes de la corrección de edades.
Elegible para severidad	895.827	99,04 %	Seis registros adicionales no informan gravedad.

La distribución espacial de los 895.833 accidentes elegibles antes de la corrección final de edad se observa en la Figura 4.




Figura 4. Accidentes depurados dentro del perímetro urbano. Fuente: elaboración propia.

3.3. Limpieza por tabla y decisiones de diseño

- 1. Normalización de identificadores.** Los identificadores se convierten a un formato comparable antes de evaluar unicidad, relaciones y duplicados.

2. **Consolidación temporal.** La fecha y la hora se integran en FECHA_HORA y se derivan los componentes necesarios para el modelado.
3. **Depuración espacial.** Las coordenadas se convierten a valores numéricos, se restringen al perímetro urbano y se proyectan a EPSG:3116 cuando se requieren distancias métricas.
4. **Reducción de VIA.** De 603.625 filas relacionadas se conserva una vía representativa determinística por accidente. Antes de la corrección final resultan 488.662 filas; 114.963 eran registros adicionales y 407.171 accidentes no tenían una fila de vía disponible.
5. **Depuración de actores y vehículos.** Se eliminan duplicados por accidente y entidad, se conservan 1.928.580 actores y 1.670.699 vehículos antes del filtro final de edades y se mantiene la relación opcional entre actor y vehículo.
6. **Tratamiento de causas.** Se eliminan filas sin causa y duplicados, se recuperan cuatro nombres a partir del código y se obtienen 1.284.682 causas antes de la corrección final.
7. **Faltantes y privacidad.** Los campos categóricos no reportados se etiquetan como SIN INFORMACION; N_CALZADAS y N_CARRILES se completan respectivamente con 1 y 2 cuando corresponde. Se retiran placas, fechas de nacimiento, OBJECTID y campos técnicos o redundantes.
8. **Corrección transversal de edad.** La identificación de edades no válidas lleva a retirar 487 accidentes y todas las filas relacionadas, con el fin de mantener integridad referencial.

El efecto de la corrección final sobre cada entidad se cuantifica en la Tabla 6; la variación confirma que la eliminación se propagó a todas las relaciones afectadas.

Tabla 6. Efecto de la corrección transversal por edades no válidas.


Tabla	Filas antes del ajuste	Filas retiradas	Porcentaje retirado
ACCIDENTE	895.833	487	0,054 %
VIA	488.662	249	0,051 %
VEHICULO	1.670.699	947	0,057 %
ACTOR_VIAL	1.928.580	1.094	0,057 %
CAUSA	1.284.682	847	0,066 %
CLIMA	325.314	84	0,026 %

3.4. Integración meteorológica

La información meteorológica histórica se obtiene mediante Open-Meteo y se integra de acuerdo con la disponibilidad y resolución de cada fuente. Para los eventos anteriores a 2017 se utiliza ERA5, con cuatro nodos y una resolución aproximada de 25 a 28 km. Desde 2017 se emplea ECMWF IFS, cuya mayor resolución permite identificar 16 nodos candidatos, de los cuales 15 se relacionan con los accidentes analizados. Cada evento se asigna al nodo más cercano y a la observación horaria correspondiente. Para IFS, la distancia media entre el accidente y el nodo asignado es de 3.043,9 m; la mediana es de 3.185,2 m; el percentil 95 alcanza 4.702,8 m; y la distancia máxima es de 5.232,3 m (Open-Meteo, s. f.-a).

La diferencia de resolución espacial entre los cuatro nodos ERA5 y las áreas de proximidad de los nodos IFS se observa en la Figura 5.

Cobertura meteorológica sobre el perímetro urbano de Bogotá



IFS: los puntos rojos corresponden a nodos identificados mediante Open-Meteo; los polígonos representan áreas de proximidad derivadas.

Figura 5. Cobertura meteorológica ERA5 e IFS sobre Bogotá. Fuente: elaboración propia.

Los controles de cobertura, deduplicación y consistencia de la integración meteorológica se consolidan en la Tabla 7.

Tabla 7. Validación de la asociación entre accidentes y clima.

Control	Resultado	Lectura
Accidentes elegibles asociados	895.833 de 895.833	Cobertura de 100 % antes de la corrección final.
Observaciones climáticas únicas	325.314	Se reutiliza la misma hora y nodo para eventos compatibles.
Duplicados evitados	570.519	La normalización reduce repetición sin perder trazabilidad.
Observaciones ERA5	155.274	Asignación correcta para el periodo anterior a 2017.
Observaciones IFS	170.040	Asignación correcta desde 2017.
Climas finales tras corrección	325.230	84 observaciones dejan de estar relacionadas.
Claves faltantes o duplicadas	0	CLIMA_ID conserva unicidad e integridad.

3.5. Tablas finales y validación

Las dimensiones y la granularidad de los archivos depurados utilizados posteriormente se especifican en la Tabla 8.

Tabla 8. Dimensiones de los archivos depurados utilizados para modelado.

Tabla	Filas	Columnas	Granularidad
ACCIDENTE	895.346	7	Una fila por accidente.
VIA	488.413	12	Cero o una vía representativa por accidente.
CLIMA	325.230	11	Una observación por identificador de clima.
VEHICULO	1.669.752	4	Una fila por vehículo.
ACTOR_VIAL	1.927.486	7	Una fila por actor vial.
CAUSA	1.283.835	6	Una fila por causa depurada.

La validación final confirma que las llaves primarias son únicas, que no existen relaciones huérfanas y que cada una de las seis tablas conserva la granularidad definida. Con estas comprobaciones, la base queda preparada para construir los conjuntos de datos utilizados en el modelado.

4. Modelo relacional ajustado

4.1. Análisis de la base relacional original

La base original distribuye la información entre ACCIDENTE, VIA, VEHICULO, ACTOR_VIAL, CAUSA, LESIONADO y MUERTO. El análisis de esta estructura permitió identificar campos temporales y espaciales repetidos, identificadores técnicos propios de la fuente, relaciones construidas con varias llaves, atributos sensibles y múltiples filas asociadas a un mismo accidente. A partir de esta revisión se definió la granularidad de cada entidad y la información que debía conservarse en la estructura propuesta para PrediRuta.




Figura 7. Modelo relacional final de PrediRuta. Fuente: elaboración propia.

El modelo relacional final concentra la información necesaria sin repetir atributos en tablas adicionales. ACCIDENTE contiene el núcleo espacial y temporal; VIA conserva las características viales seleccionadas; CLIMA reúne el perfil meteorológico horario; y VEHICULO, ACTOR_VIAL y CAUSA aportan el contexto utilizado en los análisis posteriores.

5. ETL y construcción de los datasets analíticos

5.1. Flujo implementado

La construcción de los conjuntos analíticos toma como entrada las seis tablas depuradas y genera un producto con la granularidad requerida por cada objetivo. En primer lugar, se crean diccionarios categóricos reproducibles: el código 0 se reserva para SIN INFORMACION y las demás categorías se ordenan alfabéticamente dentro de cada tabla y variable. Posteriormente, se generan copias codificadas para el modelado, sin perder la correspondencia con los valores originales.

- 1. Carga de tablas finales.** Se leen ACCIDENTE, VIA, CLIMA, VEHICULO, ACTOR_VIAL y CAUSA y se verifican sus llaves y tipos.
- 2. Diccionario de categorías.** Se asignan códigos reproducibles por tabla y variable. En CAUSA se utiliza el nombre como señal analítica y el código se conserva como referencia.
- 3. Unidad espacial.** Las coordenadas se proyectan a EPSG:3116, se agrupan primero en celdas de 500 m y después se reducen a 150 zonas mediante MiniBatchKMeans con semilla 42, lotes de 10.000 observaciones y n_init igual a 3.

4. **Dataset de ocurrencia.** Se genera el producto cartesiano de 150 zonas, 12 meses, 7 días de la semana y 24 horas. La etiqueta vale 1 si el patrón aparece alguna vez en el histórico y 0 si nunca aparece.
5. **Climatología por patrón.** Cada zona se relaciona con el nodo más cercano. Las variables se agregan por mes, día y hora; ERA5 e IFS se ponderan por horas disponibles y la dirección del viento se promedia de forma circular.
6. **Dataset por evento.** Se conserva una fila por accidente con ubicación, tiempo, clima, clase y gravedad, sin multiplicar el evento por actores o vehículos.
7. **Tabla completa.** Se construye una fila por actor y una fila sin actor para los accidentes que carecen de uno, integrando información del evento, vía, vehículo y clima.
8. **Exportación.** Se generan el diccionario y los tres archivos que alimentan los modelos.

Las dimensiones, unidades de análisis y usos de los productos generados por el ETL se resumen en la Tabla 9.

Tabla 9. Productos analíticos utilizados en la fase de modelado.

Archivo	Filas	Columnas	Unidad de análisis	Uso
DICCIONARIO_CATEGORIAS.csv	237	4	Categoría codificada	Interpretar variables categóricas.
DATASET_OCURRENCIA.csv	302.400	16	Zona-mes-día-hora	Aportar patrones, centroides y climatología a la cuadrícula anual.
Dataset temporal de ocurrencia	6.048.000	17	Año-zona-mes-día-hora	Entrenar, seleccionar y probar temporalmente el modelo de ocurrencia.
DATASET_EVENTOS.csv	895.346	23	Accidente	Base para el objetivo de clase.
TABLA_COMPLETA_MODELADO.csv	1.928.614	47	Actor o accidente sin actor	Base integrada para clase y estado.

5.2. Interpretación del objetivo de ocurrencia

Las 302.400 filas de DATASET_OCURRENCIA resultan de $150 \times 12 \times 7 \times 24$ y resumen la recurrencia de todo el histórico. Para evaluar temporalidad se incorpora ANIO y se reconstruye la cuadrícula para cada periodo, lo que produce 6.048.000 observaciones. En ambos productos, el valor 0 representa una combinación sin accidentes observados y no una medición de exposición vehicular. El modelo aprende diferencias relativas entre patrones y no una probabilidad individual calibrada.

Los usos válidos y las interpretaciones que deben evitarse para cada unidad de análisis se delimitan en la Tabla 10.

Tabla 10. Granularidad y uso permitido de los datasets.

Dataset	Objetivo	Uso válido	Uso que debe evitarse
Ocurrencia temporal	OCURRIO_ACCIDENTE	Evaluar generalización por año y ordenar patrones espaciales y temporales.	Presentar el score como probabilidad individual o exposición real.

Dataset	Objetivo	Uso válido	Uso que debe evitarse
Eventos	CLASE_ACCIDENTE	Clasificar una observación por accidente sin ponderarla por actores.	Usar variables posteriores al evento para dar información al usuario.
Tabla completa	ESTADO	Analizar el estado por actor y comparar escenarios descriptivos u operativos.	Personalizar la ruta con edad, género o atributos de personas involucradas.

5.3. Validación de los productos

Los productos generados conservan la relación con las seis tablas depuradas y con los diccionarios categóricos utilizados durante la codificación. Además, cada conjunto presenta las dimensiones, llaves y variables definidas para su respectivo nivel de análisis: patrón espaciotemporal, accidente o actor vial.

Las comprobaciones de dimensiones, llaves, categorías y cobertura climática se registran en la Tabla 11.

Tabla 11. Validación de los productos del ETL.

Control	Resultado	Evidencia
Dimensiones	Correcto	Las filas y columnas coinciden con la granularidad definida para cada archivo.
Llaves	Correcto	Los identificadores conservan la trazabilidad entre eventos, actores, vehículos, vías, causas y clima.
Categorías	Correcto	El diccionario permite interpretar las variables codificadas y reserva el valor 0 para SIN INFORMACION.
Cobertura climática	Correcto	Los patrones de ocurrencia y los eventos elegibles disponen de las variables meteorológicas requeridas.

6. Diseño común de los experimentos

6.1. Modelos y métricas

Para los tres objetivos se compara una línea base interpretable con modelos de mayor flexibilidad. La regresión logística establece el punto de referencia; Random Forest permite representar relaciones no lineales y revisar la importancia de las variables; XGBoost combina árboles de manera secuencial para capturar interacciones; y MLP evalúa una red neuronal con dos capas ocultas. Debido al desbalance de los objetivos, la selección no se realiza únicamente con accuracy, sino con métricas que consideran el desempeño de las clases minoritarias. La función de cada métrica y la dirección esperada de mejora se explican en la Tabla 12.

Tabla 12. Función de las métricas utilizadas en los experimentos.

Métrica	Uso en el análisis	Dirección deseada
ROC-AUC	Mide la capacidad de ordenar positivos por encima de negativos; se extiende con promedio macro en multiclase.	Mayor.
F1 / F1 macro	Equilibra precisión y recall; el promedio macro asigna el mismo peso a cada clase.	Mayor.

Métrica	Uso en el análisis	Dirección deseada
Balanced accuracy	Promedia el recall de las clases y evita que la mayoritaria domine la evaluación.	Mayor.
Precisión	Cuantifica qué proporción de las predicciones positivas es correcta.	Mayor.
Recall	Mide la proporción de casos positivos o de cada clase recuperada por el modelo.	Mayor.
PR-AUC macro	Resume precisión y recall y resulta sensible a las clases poco frecuentes.	Mayor.
Log loss	Evalúa la calidad de las probabilidades y penaliza predicciones incorrectas con alta confianza.	Menor.
Brier / ECE	Revisan error probabilístico y diferencia entre confianza y frecuencia observada.	Menor.

Las ventajas, limitaciones y pruebas asociadas a cada alternativa de modelado se comparan en la Tabla 13.

Tabla 13. Alternativas de modelado y función dentro del plan de pruebas.

Alternativa	Ventaja	Limitación	Prueba asociada
Regresión logística	Proporciona una referencia interpretable y de bajo costo computacional.	Representa una frontera lineal y puede perder interacciones no lineales.	Línea base regularizada y comparación temporal con modelos flexibles.
Random Forest	Captura no linealidad y permite revisar importancia de variables.	Puede sobreajustarse y generar probabilidades poco estables.	Control de profundidad y hojas; evaluación en periodos posteriores.
XGBoost	Modela interacciones complejas y suele mejorar la discriminación.	Es sensible a parametrización, desbalance y deriva temporal.	Selección en validación temporal y prueba futura aislada.
MLP	Ofrece una frontera flexible para relaciones complejas.	Requiere escalamiento, mayor control de convergencia y ofrece menor interpretabilidad.	Estandarización, regularización, parada temprana y validación temporal.

6.2. Supuestos y tratamientos

La verificación de supuestos se realiza antes del entrenamiento y se repite en cada partición cuando la condición evaluada puede cambiar con el tiempo. La revisión no se limita al tipo de variable ni a las relaciones lineales. También comprende la unidad de análisis, la disponibilidad real de los predictores, la separación cronológica, la presencia de valores faltantes, el desbalance y los cambios de prevalencia.

Estos controles permiten distinguir el desempeño propio del modelo frente a resultados artificialmente favorables producidos por duplicaciones, fuga de información o mezcla de observaciones de distintos años. Los controles aplicados y su efecto sobre la interpretación de los resultados se sintetizan en la Tabla 14.

Tabla 14. Supuestos de datos verificados antes y durante el modelado.

Supuesto	Prueba o evidencia	Tratamiento aplicado	Consecuencia
Calidad de datos	Llaves, fecha, hora, coordenadas y cobertura climática.	Filtrado por reglas explícitas y validación relacional.	La base final conserva 895.346 accidentes.
Granularidad	Conteo de patrones, eventos y actores.	Un dataset diferente para cada objetivo.	Se evita multiplicar accidentes por actores o vehículos.
Tipo y consistencia del objetivo	Comprobación de clases válidas y unicidad de las llaves que definen cada observación.	Conversión explícita de ocurrencia a 0 o 1 y exclusión de etiquetas sin información en los objetivos multiclase.	Cada modelo recibe un objetivo compatible con clasificación.
Fuga de información	Revisión de variables disponibles antes de predecir y separación cronológica sin fechas compartidas.	Exclusión de identificadores, objetivos y variables posteriores; ajuste de transformaciones solo con entrenamiento.	La prueba futura permanece aislada hasta finalizar la selección.
Faltantes	Perfil por variable y escenario.	Imputación dentro del pipeline.	La transformación se aprende solo con entrenamiento.
Variables categóricas	Revisión de dominio para zona, mes, día de la semana y hora.	Codificación one-hot con manejo de categorías no observadas.	Los códigos no se interpretan como magnitudes continuas.
Colinealidad climática	Matriz de correlación y umbral absoluto de 0,80.	Selección de variables meteorológicas no redundantes.	Se reduce la duplicación de señal entre variables equivalentes.
Desbalance y cambio de prevalencia	Distribución del objetivo por clase, partición y año.	Pesos de clase; muestreo de negativos solo en entrenamiento; F1, balanced accuracy, precisión y recall.	Validación y prueba conservan su prevalencia real.
Validación temporal	Evaluación de poder predictivo temporal del modelo y métricas entre años posteriores al entrenamiento.	Cortes cronológicos y sensibilidad en periodos de fechas posteriores al entrenamiento.	La evaluación principal mide generalización fuera de tiempo.
Aporte del clima	Mismo algoritmo y las mismas filas con y sin variables meteorológicas.	Comparación de métricas y umbral relativo del 5 %.	El clima no se incorpora al score actual.

Como complemento, la Tabla 15 diferencia los riesgos propios de cada familia de modelos y el control aplicado en cada caso.

Tabla 15. Supuestos y controles específicos por familia de modelo.

Familia	Supuesto o riesgo	Verificación	Control aplicado
Regresión logística	La señal se representa mediante una frontera lineal en el espacio transformado y puede ser sensible a escalas y colinealidad.	Correlaciones, comparación con modelos no lineales y desempeño temporal.	Estandarización de continuas, regularización y uso como línea base interpretable.
Random Forest	La flexibilidad puede capturar relaciones no lineales, pero aumenta el riesgo de sobreajuste.	Diferencia entre validación y prueba temporal.	Profundidad máxima, mínimo de observaciones por hoja, muestreo de variables y ponderación balanceada.

Familia	Supuesto o riesgo	Verificación	Control aplicado
XGBoost	Las interacciones y árboles secuenciales mejoran el ajuste, con riesgo de especialización al periodo de entrenamiento.	Selección en 2021–2023, prueba aislada en 2024–2026 y diagnóstico anual.	Profundidad y tasa de aprendizaje moderadas, submuestreo de filas y columnas, y evaluación temporal.
MLP	El entrenamiento depende de la escala y puede detenerse en una solución inestable o sobreajustada.	Convergencia del optimizador y desempeño en validación temporal.	Estandarización, regularización L2, máximo de iteraciones y parada temprana.

7. Modelo de ocurrencia de accidente

7.1. Objetivo y cambio metodológico

El modelo de ocurrencia busca identificar patrones espaciales y temporales asociados con la presencia histórica de accidentes. El conjunto inicial contiene 302.400 combinaciones de zona, mes, día de la semana y hora, y permite describir la recurrencia observada durante todo el periodo.

La cuadrícula combina cada año entre 2007 y 2026 con 150 zonas, 12 meses, siete días de la semana y 24 horas. Cada observación recibe el valor 1 cuando existe al menos un accidente para esa combinación durante el año correspondiente y 0 cuando no se registra ninguno. El conjunto resultante contiene 6.048.000 filas. Las asociaciones lineales entre las variables numéricas del modelo de ocurrencia se exploran en la Figura 8.




Figura 8. Matriz de correlación del dataset de ocurrencia. Fuente: elaboración propia.

La matriz de correlación permite identificar variables que representan información similar, por esta razón, se retiran variables con alta correlación (>80%) del set de datos para iniciar el entrenamiento de modelos. El cambio en el número y la proporción de combinaciones positivas para una regresión logarítmica entre 2007 y 2026 se observa en la Figura 9.




Figura 9. Evolución anual de los patrones positivos de ocurrencia. Fuente: elaboración propia.

La proporción de combinaciones con accidente presenta variaciones entre los periodos analizados: corresponde al 8,74 % en entrenamiento, al 6,99 % en validación y al 3,45 % en prueba. Esta diferencia refleja cambios en la frecuencia de los patrones positivos a lo largo del tiempo y constituye una característica relevante del escenario de evaluación. Por esta razón, se mantiene una partición temporal de los datos, de manera que el modelo sea entrenado con periodos anteriores y evaluado sobre periodos posteriores. Este esquema permite valorar su capacidad de generalización ante condiciones temporales distintas a las observadas durante el entrenamiento y representa de forma más adecuada el contexto previsto de uso. Los tres períodos y sus diferencias de prevalencia se detallan en la Tabla 16.

Tabla 16. Partición temporal del modelo de ocurrencia.

Conjunto	Años	Filas	Positivos	Prevalencia
Entrenamiento	2007-2020	4.233.600	369.842	8,7359 %
Validación	2021-2023	907.200	63.374	6,9857 %
Prueba	2024-2026	907.200	31.267	3,4465 %

Cada partición cumple una función distinta. El periodo 2007-2020 permite aprender los parámetros y las transformaciones; 2021-2023 se utiliza para comparar algoritmos, configuraciones y escenarios con o sin clima; y 2024-2026 permanece aislado hasta que finaliza la selección. Esta secuencia evita que la información futura influya en las decisiones de modelado y convierte la prueba final en una evaluación de generalización fuera de tiempo, no en una repetición del ajuste histórico.

7.2. Paso a paso de la metodología

- 1. Construcción anual.** Se recupera el año de cada accidente y se construye la cuadrícula completa de año, zona, mes, día de la semana y hora.
- 2. Verificación de integridad.** Se comprueba que las llaves temporales no estén duplicadas, que el objetivo solo contenga los valores 0 y 1 y que todas las zonas dispongan de un centroide.

3. **Separación temporal.** Los años entre 2007 y 2020 se destinan al entrenamiento, el periodo 2021-2023 se utiliza para validación y los años 2024-2026 permanecen aislados para la prueba final.
4. **Muestreo para el entrenamiento.** Se conservan todas las observaciones positivas (modelos de estado de víctima y clase de accidente) y se seleccionan de forma reproducible hasta 500.000 observaciones negativas (modelo ocurrencia). Los conjuntos de validación y prueba mantienen su distribución original.
5. **Definición de escenarios.** El escenario sin clima utiliza zona, mes, día de la semana y hora. El escenario con clima incorpora humedad, nubosidad, presión, velocidad del viento y dirección del viento.
6. **Preprocesamiento.** Las variables categóricas se transforman mediante codificación one-hot. Las variables continuas se imputan con la mediana y se estandarizan dentro del mismo pipeline de entrenamiento.
7. **Comparación en validación.** La regresión logística, Random Forest, XGBoost y MLP se entrenan únicamente con la partición de entrenamiento y se comparan en el periodo 2021-2023.
8. **Selección y prueba final.** El modelo se selecciona con el mayor F1; ROC-AUC y balanced accuracy se utilizan como criterios de desempate. Después del reajuste con información de 2007 a 2023, la prueba 2024-2026 se consulta una sola vez.
9. **Diagnóstico de estabilidad.** El desempeño se revisa por año y se compara con una partición aleatoria utilizada únicamente como análisis de sensibilidad. Finalmente, se exportan el pipeline, los metadatos y los centroides requeridos para la implementación.

7.3. Configuración y selección mediante validación temporal (modelo ocurrencia)

La validación temporal reproduce la decisión que deberá tomar el prototipo: asignar criticidad a combinaciones espaciotemporales posteriores a las utilizadas para entrenar. Todos los candidatos se ajustan con las observaciones de 2007 a 2020 y se comparan sobre 2021-2023. El umbral de cada candidato se determina exclusivamente en validación mediante la maximización de balanced accuracy. La selección se ordena por mayor balanced accuracy, mayor ROC-AUC y menor log loss. La Tabla 17 registra las configuraciones evaluadas para los escenarios con y sin clima.

Tabla 17. Configuraciones utilizadas en la evaluación temporal de ocurrencia.

Modelo	Configuración evaluada
Regresión logística	Elastic Net; C = 0,001, 0,01 y 0,1; l1_ratio = 0,5 y 1,0; solver saga; máximo 1.000 iteraciones.
Random Forest	100 y 150 árboles; profundidad máxima 10; min_samples_split = 2 y 5.
XGBoost	Inicial: 50, 100 y 150 árboles; profundidad 3, 6 y 10; learning_rate = 0,01, 0,1 y 0,2. Refinada: 150, 250 y 350 árboles; profundidad 6 y 10; learning_rate = 0,1 y 0,2.
MLP	Capas ocultas (64) y (64, 32); alpha = 0,0001 y 0,001; learning_rate_init = 0,001; máximo 100 iteraciones y parada temprana.

El mejor resultado de cada familia y escenario sobre las mismas filas futuras se resume en la Tabla 18.

Tabla 18. Resultados temporales de ocurrencia en validación 2021-2023.

Modelo	Clima	ROC-AUC	F1	BA	Prec.	Recall	Log loss
MLP	Sí	0,6661	0,1781	0,6234	0,1011	0,7449	0,4234
MLP	No	0,6568	0,1751	0,6202	0,0989	0,7637	0,4303
XGBoost refinado	Sí	0,6632	0,1768	0,6201	0,1004	0,7356	0,4310
XGBoost refinado	No	0,6569	0,1756	0,6166	0,1000	0,7222	0,4268
Logística	Sí	0,6542	0,1754	0,6135	0,1004	0,6966	0,4362
Logística	No	0,6521	0,1745	0,6120	0,0997	0,6978	0,4288
Random Forest	No	0,6415	0,1720	0,6115	0,0974	0,7367	0,4376
Random Forest	Sí	0,6293	0,1640	0,6014	0,0913	0,8064	0,4377

La red neuronal MLP con clima ocupa el primer lugar de la validación del modelo de ocurrencia: balanced accuracy de 0,6234, ROC-AUC de 0,6661 y F1 de 0,1781. La misma arquitectura sin clima alcanza 0,6202, 0,6568 y 0,1751, respectivamente. El incremento relativo del escenario con clima es pequeño (aproximadamente 0,52 % en balanced accuracy, 1,42 % en ROC-AUC y 1,71 % en F1), pero resulta suficiente para ocupar el primer lugar bajo el criterio de selección implementado. Esta decisión debe distinguirse del umbral de mejora de 5 % definido previamente para RA03, que no se alcanza y que se consolida llevar como modelo productivo al despliegue; sin embargo, se tomará el modelo con variables climáticas debido a la mejora de rendimiento y es una variable que se proyectó presentar como variables de respuesta del proyecto.

7.4. Prueba temporal del modelo seleccionado

Una vez seleccionada la MLP con clima, el pipeline entrenado con 2007-2020 se evalúa una sola vez sobre 2024-2025, periodo que permaneció aislado durante la selección. Para esta prueba se conserva el umbral 0,3090 obtenido en validación. Solo después de medir el desempeño final, el pipeline se reajusta con entrenamiento y validación, es decir, con la información disponible hasta 2023, para su exportación. La Tabla 19 compara el desempeño de la configuración ganadora en validación y en la prueba temporal.

Tabla 19. Validación y prueba temporal de la MLP con clima para ocurrencia.

Métrica	Validación 2021-2023	Prueba temporal 2024-2025
ROC-AUC	0,6661	0,6308
F1	0,1781	0,1055
Balanced accuracy	0,6234	0,5981
Precisión	0,1011	0,0571
Recall	0,7449	0,6920
Log loss	0,4234	0,4047

La matriz de confusión de la Figura 10 muestra el tipo y la magnitud de los errores cometidos sobre las 604.800 combinaciones de la prueba temporal.




Figura 10. Matriz de confusión de la MLP con clima en la prueba temporal 2024-2025. Fuente: elaboración propia.

Al pasar de validación con data con fechas más recientes, el ROC-AUC disminuye 5,30 %, el F1 se reduce 40,76 % y balanced accuracy baja 4,06 %. El recall se mantiene en 0,6920, pero la precisión desciende a 0,0571. Con el umbral 0,3090, el modelo identifica 17.405 de los 25.151 patrones positivos y omite 7.746; al mismo tiempo, genera 287.389 falsos positivos y 292.260 verdaderos negativos. La tasa de positivos predichos es 50,40 %, muy superior a la prevalencia observada de 4,16 %. Por ello, la salida es útil para priorización relativa, pero no se presentará como una probabilidad calibrada ni como una predicción determinística de accidente.

Esta evaluación se vincula directamente con los requerimientos analíticos. RA05 se verifica durante 2021-2023 al seleccionar la mayor balanced accuracy y usar ROC-AUC y log loss como desempates. RA02 se evalúa sobre 2024-2025: el deterioro de ROC-AUC se mantiene dentro del límite de 10 %, mientras que el F1 lo supera, por lo que el cumplimiento continúa siendo parcial. RA03 no cumple el umbral relativo de 5 %, aunque el notebook actual selecciona el escenario con clima por su primer lugar en balanced accuracy. RA04 se validará con los niveles Bajo, Medio y Alto (valor de certeza de un escenario similar de 0 a 0.3, 0.3 a 0.6 y 0.6 a 1.0).

7.5. Selección y uso del modelo de ocurrencia

La MLP con variables climáticas se selecciona porque obtiene la mayor balanced accuracy en la validación temporal. La arquitectura ganadora tiene dos capas ocultas de 64 y 32 neuronas, alpha de 0,001, tasa de aprendizaje inicial de 0,001 y parada temprana. El pipeline final se reajusta con 2007-2023 y se exporta junto con sus metadatos y los centroides de las 150 zonas. La inferencia requiere zona, fecha y hora, además de temperatura, precipitación, nubosidad, presión, velocidad y dirección del viento. **El score se interpreta como propensión comparativa del patrón espaciotemporal**, no como probabilidad individual de accidente.

El notebook exporta el score y una clasificación binaria con el umbral validado de 0,3090. No define ni valida dos puntos de corte para producir tres niveles de criticidad; por tanto, los límites de Bajo, Medio y Alto deben interpretarse antes de implementarlos en la interfaz.

Tabla 20. Salidas y regla de decisión exportadas por el modelo de ocurrencia.

Salida	Valor o regla	Interpretación
Score	$0,00 \leq p \leq 1,00$	Propensión comparativa del patrón espaciotemporal; no es una probabilidad individual calibrada.
Umbral binario	0,3090	Punto de corte seleccionado en validación al maximizar balanced accuracy.
Clasificación	0 si $p < 0,3090$; 1 si $p \geq 0,3090$	Indicador binario exportado por la función de inferencia.

8. Modelo de estado del actor vial

8.1. Objetivo y distribución

El modelo de estado clasifica a cada actor vial involucrado en un accidente como HERIDO, ILESO o MUERTO. Los registros SIN INFORMACION se excluyen porque representan ausencia del dato y no una consecuencia observada. La distribución presenta un desbalance considerable: la categoría MUERTO representa menos de 1 % de las observaciones. Por esta razón, F1 macro y balanced accuracy tienen mayor importancia que accuracy durante la comparación de los modelos. Este desbalance que orienta la selección de métricas y el uso de pesos de clase se cuantifica en la Tabla 21.

Tabla 21. Distribución del estado del actor vial.

Estado	Registros	Participación
HERIDO	475.035	24,7326 %
ILESO	1.430.090	74,4575 %
MUERTO	15.555	0,8099 %

8.2. Escenarios, variables y validación temporal

El análisis de correlación permite retirar variables meteorológicas redundantes. SENSACION_TERMICA presenta una correlación de 0,962 con TEMPERATURA, LLUVIA alcanza 0,995 con PRECIPITACION y HUMEDAD_RELATIVA registra -0,827 con

TEMPERATURA. Los escenarios completos conservan variables de la vía, del actor y del vehículo, mientras que los escenarios operativos reducen el número de entradas. Aun así, estos últimos requieren edad, género, clase de vehículo y servicio del vehículo, atributos que no se habían planeado incluir en el formulario de consulta; sin embargo, validando la importancia de estas variables en el modelo se plantea la incursión en la captura de información. Los cuatro escenarios comparados y la diferencia entre disponibilidad analítica y operativa se describen en la Tabla 22.

Tabla 22. Escenarios evaluados para el estado del actor.

Escenario	Número de entradas	Contenido principal	Uso
Completo sin clima	29	Tiempo, espacio, actor, vehículo y contexto disponible.	Referencia analítica ampliada.
Completo con clima	36	Escenario completo más variables meteorológicas.	Medir aporte incremental.
Operativo sin clima	16	Celda, zona, edad, género, vehículo y variables temporales.	Candidato analítico..
Operativo con clima	23	Escenario operativo más clima no redundante.	Comparación meteorológica.

La distribución por periodos de la Tabla 23 evidencia un cambio temporal marcado en la composición de las clases; los actores del mismo accidente permanecen en una única partición.

Tabla 23. Partición temporal del modelo de estado.

Conjunto	Años	Actores	Accidentes	HERIDO	ILESO	MUERTO
Entrenamiento	2007-2020	1.696.736	794.835	21,362 %	77,901 %	0,737 %
Validación	2021-2023	148.173	67.322	41,717 %	57,238 %	1,045 %
Prueba	2024-2026	75.771	31.862	66,997 %	31,021 %	1,982 %

8.3. Entrenamiento y selección

Los modelos se entrenan sobre una muestra estratificada común de 300.000 filas, de manera que todas las alternativas se comparen con las mismas observaciones. XGBoost en el escenario operativo sin clima supera la línea base y los demás modelos entrenados, y se selecciona para el ajuste final. La configuración utiliza 240 árboles, profundidad máxima de 4, tasa de aprendizaje de 0,08, min_child_weight de 10 y una potencia de ponderación de clase de 0,90.

La comparación con la línea base se consigna en la Tabla 24 y confirma una mejora sustancial del XGBoost operativo sin clima en todas las métricas disponibles.

Tabla 24. Resultados de validación del escenario operativo seleccionado para estado.

Métrica	Línea base	XGBoost operativo sin clima
Accuracy	0,5724	0,8072
Balanced accuracy	0,3333	0,5874

Métrica	Línea base	XGBoost operativo sin clima
F1 macro	0,2427	0,5758
F1 ponderado	No reportado	0,8098
PR-AUC macro	No reportado	0,5922
ROC-AUC macro	0,5000	0,8614
Log loss	0,8382	0,5463

La comparación conjunta de familias de modelos y escenarios que conduce a la selección de XGBoost se resume en la Figura 11.

Comparación de modelos por alcance, disponibilidad de clima y métrica




Figura 11. Comparación de modelos para el estado del actor. Fuente: elaboración propia.

La comparación bootstrap entre los escenarios operativos muestra que la incorporación del clima aumenta el F1 macro en 0,0014, con un intervalo de confianza entre -0,0007 y 0,0039. Para balanced accuracy, la diferencia es de 0,0010 y el intervalo se encuentra entre -0,0020 y 0,0040. Aunque log loss mejora 0,0016, el cambio no alcanza el umbral de 5 % definido para las métricas principales, por lo que se conserva el escenario sin clima. La diferencia entre el escenario completo y el operativo es mayor: F1 macro aumenta 0,0696 y balanced accuracy 0,0651. Esto indica que los atributos del actor, del vehículo y del contexto posterior al evento aportan información, pero no pueden utilizarse en la consulta de una ruta porque todavía no existen en ese momento. A diferencia que el modelo de ocurrencia, el valor que aporta las variables climáticas no hace que sea significativa su inclusión dentro del modelo predictivo y por esta razón no se consideran.

8.4. Prueba temporal final

Las dos ventanas de backtesting registradas en la Tabla 25 permiten comprobar la estabilidad previa a la prueba final.

Tabla 25. Backtesting temporal del modelo de estado.

Entrenamiento	Validación	F1 macro	BA	ROC-AUC	Log loss
Hasta 2016	2017-2018	0,5639	0,6123	0,8559	0,5015
Hasta 2018	2019-2020	0,5694	0,6091	0,8659	0,5067

Para la evaluación final, el pipeline se reajusta con una muestra de 600.000 actores obtenida de las 1.844.909 observaciones registradas entre 2007 y 2023. El periodo 2024-2026 se mantiene como prueba independiente. En este conjunto, el modelo alcanza una accuracy de 0,7747, balanced accuracy de 0,5926, F1 macro de 0,5688, F1 ponderado de 0,7821, PR-AUC macro de 0,5747 y ROC-AUC macro de 0,8367. Las métricas probabilísticas corresponden a un log loss de 0,6091, un Brier multiclase de 0,3474 y un ECE de 0,0637. El intervalo bootstrap del F1 macro se encuentra entre 0,5623 y 0,5748, mientras que el de balanced accuracy se ubica entre 0,5840 y 0,6000. El desempeño por clase de la Tabla 26 ubica la principal limitación en MUERTO, cuyo bajo soporte y baja precisión reducen el promedio macro.

Tabla 26. Desempeño por clase del modelo de estado en 2024-2026.

Clase	Precisión	Recall	F1	Soporte
HERIDO	0,8819	0,7862	0,8313	50.764
ILESO	0,6565	0,7864	0,7156	23.505
MUERTO	0,1304	0,2051	0,1594	1.502

Las confusiones entre HERIDO, ILESO y MUERTO durante 2024-2026 se identifican en la Figura 12.




Figura 12. Matriz de confusión del modelo de estado en la prueba temporal. Fuente: elaboración propia.

El contraste de la Figura 13 confirma que el F1 macro de la partición aleatoria, 0,5834, supera el 0,5688 obtenido en la evaluación temporal.




Figura 13. Comparación entre validación temporal y partición aleatoria para estado. Fuente: elaboración propia.

La importancia por permutación de la Figura 14 indica que la clase de vehículo y variables personales como edad y género aportan parte de la señal del modelo de estado.




Figura 14. Importancia de variables del XGBoost de estado. Fuente: elaboración propia.

El desempeño anual se mantiene relativamente estable, con un F1 macro de 0,5573 en 2024, 0,5759 en 2025 y 0,5781 durante el período parcial de 2026. Sin embargo, la revisión de importancia de variables muestra que una parte relevante de la predicción depende de atributos personales y del vehículo. En consecuencia, el modelo permite analizar el estado de actores registrados en accidentes históricos, pero no debe utilizarse para personalizar la criticidad de quien consulta una ruta.

8.5. Artefactos exportados y uso permitido

Los archivos exportados y su función dentro del flujo de inferencia se relacionan en la Tabla 27.

Tabla 27. Artefactos de producción exportados por el modelo de estado.

Artefacto	Contenido	Uso
modelo_estado_actor_xgboost.joblib	Pipeline y modelo XGBoost ajustado.	Reproducir las predicciones del modelo seleccionado.
metadata_estado_actor.joblib	Metadatos necesarios para interpretar entradas y clases.	Conservar el esquema de variables y las etiquetas de salida.
centroides_zonas.csv	Centroides de las 150 zonas de análisis.	Asignar observaciones a la zonificación utilizada.

9. Modelo de clase de accidente

9.1. Objetivo y distribución

El modelo busca clasificar cada accidente como ATROPELLO, CHOQUE u OTROS. Los registros SIN INFORMACION se excluyen antes de construir las particiones porque no representan una clase válida. CHOQUE concentra la mayoría de las observaciones, por lo que accuracy puede ocultar un desempeño bajo en ATROPELLO y OTROS. Por esta razón, la evaluación prioriza F1 macro y balanced accuracy.

La composición del objetivo se cuantifica en la Tabla 28 y evidencia la predominancia de CHOQUE.

Tabla 28. Distribución de la clase de accidente.

Clase	Registros	Participación
ATROPELLO	105.206	11,7540 %
CHOQUE	742.846	82,9932 %
OTROS	47.016	5,2528 %

9.2. Escenarios y partición temporal

Para el modelo de clase se aplican las mismas reglas de selección de variables meteorológicas. SENSACION_TERMICA, LLUVIA y HUMEDAD_RELATIVA se excluyen por su alta relación con TEMPERATURA y PRECIPITACION. El escenario operativo utiliza únicamente información espacial y temporal disponible antes del evento, mientras que el escenario completo incorpora características de la vía. Ninguno de los dos escenarios incluye datos del actor, del vehículo ni variables registradas después del accidente.

Los cuatro escenarios y la cantidad de entradas utilizada en cada uno se describen en la Tabla 29.

Tabla 29. Escenarios evaluados para la clase de accidente.

Escenario	Número de entradas	Contenido principal	Propósito
Completo sin clima	23	Espacio, tiempo y características de vía.	Estimar el techo analítico con contexto vial.
Completo con clima	30	Escenario completo más clima no redundante.	Medir aporte incremental.
Operativo sin clima	12	Celda, zona y variables temporales.	Aproximar disponibilidad antes del evento.
Operativo con clima	19	Escenario operativo más clima.	Contrastar el aporte meteorológico.

La distribución temporal consignada en la Tabla 30 evidencia que la participación de ATROPELLO y OTROS aumenta durante la prueba.

Tabla 30. Partición temporal del modelo de clase.

Conjunto	Años	Eventos	ATROPELLO	CHOQUE	OTROS
Entrenamiento	2007-2020	795.386	11,401 %	83,530 %	5,069 %
Validación	2021-2023	67.444	11,580 %	82,667 %	5,753 %

Conjunto	Años	Eventos	ATROPELLO	CHOQUE	OTROS
Prueba	2024-2026	32.238	20,823 %	70,429 %	8,747 %

9.3. Selección y aporte del clima

La línea base, que asigna todos los casos a la clase mayoritaria, obtiene una accuracy de 0,8267. Sin embargo, su balanced accuracy es de 0,3333, el F1 macro alcanza 0,3017 y el ROC-AUC macro corresponde a 0,5000, lo que muestra que la accuracy elevada se explica por el predominio de CHOQUE. La selección por F1 macro favorece levemente a XGBoost operativo con clima, aunque el escenario sin clima obtiene una balanced accuracy mayor. Esta diferencia requiere revisar los intervalos de confianza antes de tomar una decisión. Los intervalos de la Tabla 31 indican que la ventaja en F1 macro no es concluyente y que balanced accuracy empeora al incorporar clima.

Tabla 31. Comparación climática del XGBoost operativo para clase.

Métrica	Sin clima	Con clima	Diferencia con clima
F1 macro	0,3742	0,3767	+0,002425; IC [-0,000434; 0,005337]
Balanced accuracy	0,4055	0,3944	-0,011067; IC [-0,013605; -0,008247]
Mejora de log loss	Referencia	Mejor	+0,048707; intervalo positivo

El desempeño de las familias y escenarios evaluados para clasificar la clase de accidente se resume en la Figura 15.




Figura 15. Comparación de modelos para la clase de accidente. Fuente: elaboración propia.

La prueba bootstrap muestra que el incremento del F1 macro al incorporar el clima no es concluyente y no alcanza el umbral relativo de 5 %. Además, balanced accuracy disminuye. El escenario con clima se mantiene únicamente como referencia para la evaluación temporal. En términos generales, ninguna de las configuraciones alcanza un desempeño suficiente para incorporar la predicción de la clase de accidente a PrediRuta.

9.4. Prueba temporal ejecutada

Los dos periodos de backtesting utilizados para revisar la estabilidad del escenario de referencia se registran en la Tabla 32.

Tabla 32. Backtesting temporal del escenario operativo con clima para clase.

Entrenamiento	Validación	F1 macro	BA	ROC-AUC	Log loss
Hasta 2016	2017-2018	0,3849	0,4012	0,6177	0,8217
Hasta 2018	2019-2020	0,3720	0,3971	0,6192	0,7571

El ajuste final utiliza una muestra de 600.000 observaciones tomada de los 862.830 accidentes registrados entre 2007 y 2023. En la prueba de 2024 a 2026, el modelo obtiene una accuracy de 0,6363, balanced accuracy de 0,3871, F1 macro de 0,3735, F1 ponderado de 0,6120, PR-AUC macro de 0,3800 y ROC-AUC macro de 0,5719. El log loss alcanza 0,9059, el Brier multiclase 0,5323 y el ECE 0,1358. El intervalo del F1 macro se encuentra entre 0,3689 y 0,3775, mientras que el de balanced accuracy se ubica entre 0,3828 y 0,3910.

El detalle por clase de la Tabla 33 evidencia que el modelo casi no recupera OTROS y concentra su desempeño en CHOQUE.

Tabla 33. Desempeño por clase en la prueba temporal del modelo de clase.

Clase	Precisión	Recall	F1	Soporte
ATROPELLO	0,3158	0,3535	0,3336	6.713
CHOQUE	0,7406	0,7976	0,7680	22.705
OTROS	0,1078	0,0103	0,0188	2.820

La concentración de predicciones en CHOQUE y las confusiones de ATROPELLO y OTROS se observan en la Figura 16.




Figura 16. Matriz de confusión del modelo de clase en la prueba temporal. Fuente: elaboración propia.

El contraste de la Figura 17 confirma que la partición aleatoria produce un F1 macro de 0,4019, superior al 0,3735 de la prueba temporal.




Figura 17. Comparación temporal y aleatoria para el modelo de clase. Fuente: elaboración propia.

La importancia por permutación de la Figura 18 señala el predominio de CELDA_Y, ZONA_CIUADAD y CELDA_X; la hora es secundaria y las variables climáticas tienen menor peso.




Figura 18. Importancia de variables del XGBoost de clase. Fuente: elaboración propia.

9.5. Conclusión del modelo de clase

El F1 macro anual se mantiene alrededor de 0,37, pero el modelo solo recupera 1,03 % de los accidentes clasificados como OTROS. Este resultado muestra que la información espacial, temporal, vial y meteorológica disponible no contiene una señal suficiente para predecir de forma confiable la clase del accidente. En consecuencia, la variable no es predecible con un desempeño aceptable bajo el conjunto actual de predictores y el modelo de clase no se incorporará a PrediRuta. El análisis se conserva como evidencia de la experimentación, pero no formará parte del backend ni de la experiencia del usuario.

10. Análisis integrado y decisiones de implementación

10.1. Decisión sobre los componentes

Los resultados permiten establecer una decisión para cada objetivo. La MLP con clima se utiliza para producir el **score de ocurrencia** y sustentar la criticidad relativa del recorrido. Debido a la baja precisión y al deterioro temporal, la salida no se comunica como probabilidad individual. El modelo de estado se conserva como análisis complementario, se incorporará al flujo solicitando los atributos de los actores adicionales. El modelo de clase se excluye de PrediRuta por su desempeño insuficiente.

En ocurrencia, la MLP con clima supera por un margen pequeño a la misma red sin clima y queda seleccionada por balanced accuracy. La mejora no alcanza el 5 % definido originalmente en RA03; por ello, el cambio de criterio queda actualizado para continuar con el despliegue. Para los modelos de estado de la víctima y clase de accidente, no habían criterios de aceptación establecidos dentro de las tablas de requerimientos, por tal razón se decide incluir el modelo de estado de la víctima como un valor adicionales al usuario durante el MVP del proyecto.

10.2. Riesgos y limitaciones que permanecen vigentes

Los riesgos identificados en la primera entrega y su tratamiento a partir de los resultados experimentales se actualizan en la Tabla 34.

Tabla 34. Riesgos, impacto y tratamiento para las siguientes fases.

Riesgo o limitación	Impacto	Tratamiento
Cambios en fuentes SDM	Pueden modificar columnas, categorías o cobertura.	QA/QC, diccionario de datos, versión de insumos y pruebas de esquema.
Resolución meteorológica	No representa microvariaciones de cada cuadra.	Validar resolución, cobertura y correspondencia temporal; documentar su efecto como predictor del score.
Exposición vehicular desconocida	No existe denominador de vehículos expuestos por tramo y momento.	No interpretar el score como probabilidad individual.
Desbalance	Clases poco frecuentes tienen bajo recall.	Métricas macro, pesos, umbrales y análisis por clase.
Deriva temporal	La prevalencia de ocurrencia y la distribución de clase y estado cambian entre periodos.	Validación temporal, monitoreo anual y criterio de reentrenamiento.
Variables posteriores al evento	Pueden producir fuga o no estar disponibles en la consulta.	Escenarios operativos y revisión estricta de RD05.
Dependencia de APIs	Rutas, tiempos o clima pueden no estar disponibles.	Manejo de excepciones, reintentos y una política explícita de contingencia, porque el modelo seleccionado requiere clima.
Interpretación del color	Un nivel bajo puede leerse como ausencia de riesgo.	Etiquetar como criticidad relativa y comunicar incertidumbre.

11. Próximos pasos y plan de implementación

11.1. Criterios de alcance para el trabajo restante

El flujo del prototipo comienza con el origen, el destino, la fecha y la hora. Google Routes construye el recorrido y entrega los tiempos estimados por segmento. Open-Meteo o Google Weather debe aportar las variables meteorológicas requeridas para el momento esperado de tránsito antes de ejecutar la MLP; luego, el modelo asigna el score de ocurrencia a cada segmento evaluable. Luego, el modelo de estado serán consultado cuando se tenga señal positivas de accidente y generará las probabilidades de encontrar cada escenario. El modelo de clase no intervendrá en este flujo. El alcance se traduce en los controles concretos de implementación y aceptación consignados en la Tabla 35.

Tabla 35. Reglas de alcance que deben verificarse antes del despliegue.

Regla	Aplicación en el prototipo	Control de aceptación
Alcance geográfico	Solo trayectos dentro del perímetro urbano de Bogotá.	Validación de origen, destino y segmentos fuera del área.
Salida relativa	Score del modelo y clasificación binaria; los niveles Bajo, Medio y Alto requieren calibración adicional.	Ninguna pantalla presenta el score como probabilidad individual; umbral y versión del modelo quedan registrados.
Clima como predictor	Pronóstico requerido por la MLP con clima y mostrado también al usuario.	Esquema, unidades, horizonte y faltantes de Open-Meteo se validan antes de la inferencia.
Variables operativas	Solo datos disponibles antes del recorrido.	Revisión de esquema de entrada y prueba RD05.
Privacidad	Informar al usuario que la información personal no será almacenada y sólo será usada para el modelo de estado de víctima.	Espacio para aceptar el manejo de los datos suministrados.

11.2. Plan por semanas

Las actividades previstas y los criterios de cierre para cada semana se organizan en la Tabla 36.

Tabla 36. Plan de implementación para las semanas 6, 7 y 8.

Semana	Objetivo	Actividades	Entregable y criterio de salida
6	Finalizar el front e integrar el backend con los modelos.	Completar la interfaz; conectar la MLP con clima; obtener y validar las variables meteorológicas; definir y validar los niveles de criticidad; integrar Google Routes y Open-Meteo; presentar los resultados sobre el mapa.	Flujo que recibe origen, destino, fecha y hora, consulta el clima requerido y devuelve segmentos con tiempo y score relativo; los niveles Bajo, Medio y Alto quedan sujetos a calibración.
7	Implementar el proyecto en Streamlit y validar los requisitos.	Empaquetar configuración; gestionar errores de APIs; ejecutar pruebas unitarias, integración y end-to-end; registrar evidencia para RN, RF, RD, RU y RA; corregir defectos.	Aplicación reproducible y matriz de requisitos con evidencia, métrica, resultado y estado.
8	Preparar la entrega final y grabar el video.	Congelar versiones; repetir pruebas críticas; preparar guion; grabar consulta completa; explicar datos, modelo, clima, limitaciones y resultados; verificar enlaces y archivos.	Video final, repositorio ordenado, documento actualizado y demostración sin intervención técnica.

11.3. Matriz de validación de la primera entrega

Durante la semana 7, los requerimientos definidos para el prototipo funcionarán como lista de control para la validación. La evaluación considera tanto la utilidad del artefacto como la validez de los procesos analíticos que sustentan sus resultados, de acuerdo con el enfoque de Design Science Research (Peppers et al., 2007). La matriz conserva únicamente los requerimientos que pueden verificarse mediante una prueba, una métrica y un criterio de

aceptación. Las formulaciones que repiten el objetivo general o describen exclusiones del alcance no se incluyen como pruebas independientes.

La validación contempla dos horizontes diferentes y complementarios. El horizonte operativo de RN02 corresponde a los siete días calendario cubiertos por la consulta y comprueba que el prototipo genere criticidad para las fechas y horas solicitadas. En cambio, la validación temporal de RA02 utiliza años posteriores al entrenamiento para comprobar que el modelo conserve su capacidad de discriminación ante cambios de prevalencia. El primer control evalúa la cobertura funcional de la consulta; el segundo evalúa la validez del modelo que produce la criticidad. La satisfacción de RN02, por sí sola, no compensa un deterioro analítico en RA02.

El requisito de negocio medible y la prueba definida para el horizonte de siete días se consignan en la Tabla 37.

Tabla 37. Requerimiento de negocio priorizado y plan de verificación.

ID	Requerimiento	Prueba, métrica y criterio	Aplicación en el plan
RN02	Generar criticidad prospectiva para una ruta, fecha y hora dentro de los siete días calendario que incluyen el día de consulta (Open-Meteo, s. f.-b).	Ejecutar al menos 28 consultas, cuatro franjas horarias por cada día del horizonte; porcentaje que genera criticidad. Criterio: al menos 27 de 28 consultas válidas ($\geq 95\%$).	Integración del modelo en semana 6 y prueba del horizonte completo en semana 7.

Los requerimientos funcionales se convierten en pruebas concretas para el front y el backend en la Tabla 38.

Tabla 38. Requerimientos funcionales y plan de verificación.

ID	Requerimiento	Prueba, métrica y criterio	Aplicación en el plan
RF01	Ingresar origen, destino, fecha y hora de salida.	Prueba del formulario; porcentaje de consultas válidas procesadas. Criterio: 100 % con campos obligatorios.	Implementación en semana 6 y validación en Streamlit durante la semana 7.
RF02	Construir y segmentar una ruta dentro de Bogotá.	Trayectos y ubicaciones diversas; porcentaje de rutas válidas. Criterio: al menos 95 % georreferenciadas.	Integración con Google Routes en semana 6 y prueba en semana 7.
RF03	Estimar la hora de tránsito de los steps mediante consultas sucesivas.	Validar tiempos retornados por Google Routes. Criterio: 100 % de tramos procesados con hora estimada.	Implementación en semana 6 y verificación temporal en semana 7.

ID	Requerimiento	Prueba, métrica y criterio	Aplicación en el plan
RF04	Asignar criticidad espaciotemporal a los tramos evaluables.	Prueba end-to-end; porcentaje de tramos clasificados y coherencia con el umbral 0,3090. Criterios: al menos 95 % clasificados y 100 % coherentes con la regla binaria; los tres niveles requieren validación adicional.	Conexión del modelo en semana 6 y prueba end-to-end en semana 7.
RF05	Consultar y mostrar condiciones meteorológicas previstas.	Pruebas con Open-Meteo forecast; porcentaje de puntos con clima. Criterio: al menos 95 %, sujeto a la fuente.	Integración del pronóstico en semana 6 y validación en semana 7.
RF06	Integrar ruta, criticidad, hora y clima en una visualización.	Revisión funcional del mapa; porcentaje de consultas que muestran correctamente los cuatro componentes disponibles. Criterio: 100 % de las consultas válidas.	Construcción del mapa en semana 6 y revisión funcional en semana 7.

La evidencia obtenida durante la preparación de los datos se contrasta con los cinco criterios de calidad y disponibilidad en la Tabla 39.

Tabla 39. Requerimientos de datos y plan de verificación.

ID	Requerimiento	Prueba, métrica y criterio	Resultado o aplicación
RD01	Disponer de siniestralidad espacial y temporalmente válida.	Validar coordenadas, fecha y hora; porcentaje utilizable. Criterio: al menos 90 %.	Cumplido: 895.833 de 904.476 registros, equivalentes a 99,04 %.
RD02	Integrar tablas SDM con trazabilidad y sin duplicación artificial.	Medir llaves primarias duplicadas, llaves foráneas huérfanas y variación artificial del total de accidentes. Criterios: 0 duplicadas, 0 huérfanas y 0 % de aumento artificial.	Cumplido mediante las validaciones relacionales.
RD03	Asociar clima histórico a eventos y momentos comparables.	Cruzar siniestros y clima; porcentaje asociado. Criterio: al menos 95 %.	Cumplido: 100 % de los eventos elegibles cuenta con clima.
RD04	Contar con cobertura espacial y temporal para entrenamiento y validación independiente.	Medir cobertura de zonas, asignación de filas y solapamiento temporal. Criterios: 150 zonas cubiertas, 100 % de filas asignadas a una partición y 0 fechas compartidas entre entrenamiento y prueba temporal.	Cumplido mediante cobertura desde 2007, 150 zonas y particiones de evaluación.

ID	Requerimiento	Prueba, métrica y criterio	Resultado o aplicación
RD05	Usar en operación solo predictores disponibles antes del recorrido.	Revisar entradas del modelo final. Criterio: 100 % disponibles al predecir.	Cumplido por el modelo de ocurrencia seleccionado para el MVP.

Las pruebas de comprensión y consistencia visual previstas para la interfaz se definen en la Tabla 40.

Tabla 40. Requerimientos de usabilidad y plan de verificación.

ID	Requerimiento	Prueba, métrica y criterio	Aplicación en el plan
RU01	Representar de forma diferenciable los niveles Bajo, Medio y Alto.	Revisar rutas y valores próximos a cada límite; porcentaje de categorías con representación diferenciable y asignación correcta. Criterio: 100 % conforme con los umbrales establecidos.	Diseño en semana 6 y prueba visual en semana 7.
RU02	Diferenciar criticidad, hora estimada y clima.	Revisar paneles de tramos. Criterio: 100 % de componentes disponibles identificados y etiquetados.	Implementación en Streamlit y verificación durante la semana 7.
RU03	Completar una consulta sin intervención técnica.	Escenarios end-to-end desde entrada hasta mapa. Criterio: 100 % de escenarios válidos.	Pruebas end-to-end en semana 7.
RU04	Comunicar criticidad relativa y no probabilidad individual.	Revisar textos, etiquetas y mensajes. Criterio: 100 % de pantallas explican el alcance.	Revisión del lenguaje de la interfaz en semana 7.
RU05	Identificar visualmente los tramos de mayor criticidad.	Comparar categoría calculada y representación. Criterio: 100 % de tramos coherentes.	Pruebas de consistencia del mapa en semana 7.

La relación entre los resultados experimentales, los criterios de aceptación y las verificaciones pendientes del prototipo se consolida en la Tabla 41.

Tabla 41. Requerimientos de desempeño analítico y plan de verificación.

ID	Requerimiento	Prueba, métrica y criterio	Resultado o aplicación
RA01	Diferenciar sectores y momentos con distinta siniestralidad histórica.	Medir la tasa observada de OCURRIO_ACCIDENTE y la proporción de la muestra en cada nivel. Criterios: tasa estrictamente creciente Bajo < Medio < Alto y al menos 5 % de observaciones en cada nivel.	Implementación en semana 6 durante la integración del frontend con los resultados de los modelos.
RA02	Conservar discriminación en periodos posteriores.	Medir ROC-AUC y F1 en una prueba temporal y su variación relativa frente a validación. Criterio: deterioro no superior al 10 % en cada métrica.	Cumplimiento parcial: ROC-AUC disminuye 5,30 %, pero F1 se reduce 40,76 %.
RA03	Evaluar el aporte incremental del clima.	Comparar el mismo enfoque con/sin clima; variación relativa. Criterio: al menos 0.5 % para incorporarlo.	Ajustado debido al aporte encontrado de las variables: la MLP con clima mejora 0,52 % en balanced accuracy, 1,42 % en ROC-AUC y 1,71 % en F1; el criterio debe conciliarse antes del despliegue.
RA04	Evitar niveles inconsistentes o inestables.	Calcular el índice de estabilidad poblacional (PSI) de los niveles entre validación y prueba temporal. Criterio: PSI menor que 0,20 y conservación del orden Bajo < Medio < Alto.	Cálculo y registro durante la validación de semana 7.
RA05	Justificar cuantitativamente el modelo final frente a las alternativas.	Comparar candidatos en la misma validación temporal. Criterios implementados: mayor balanced accuracy; ROC-AUC y menor log loss como desempates.	Cumplido: la MLP con clima obtiene balanced accuracy de 0,6234 y ROC-AUC de 0,6661, y ocupa el primer lugar de la comparación.

12. Conclusiones

La fase 2 del proyecto permitió consolidar una base relacional depurada y trazable, tres conjuntos de datos con granularidades diferentes y una comparación común para los modelos evaluados. Antes de la corrección transversal de edades, el 99,04 % de los accidentes originales cumple de forma simultánea los criterios de calidad, periodo y ubicación. Además, el clima histórico se encuentra asociado con el 100 % de los eventos

elegibles y las relaciones finales no presentan registros huérfanos. Estos resultados respaldan la calidad de la información utilizada en los experimentos.

La MLP con variables climáticas fue seleccionada para estimar la ocurrencia y sustentar la criticidad relativa del MVP. La selección se realizó entre 2021-2023 y 2024-2025 permaneció aislado. En prueba, el modelo alcanza ROC-AUC de 0,6308, F1 de 0,1055, balanced accuracy de 0,5981, recall de 0,6920 y precisión de 0,0571. Frente a validación, ROC-AUC se reduce 5,30 % y cumple el límite de RA02; F1 disminuye 40,76 % y no lo cumple. **El resultado exige comunicar el score como propensión relativa**, monitorear la deriva y definir criterios de reentrenamiento. El escenario con clima ocupa el primer lugar. El modelo de estado conserva valor analítico, pero no es una entrada del MVP.

El modelo de clase de accidente no se incorpora a PrediRuta. Las variables espaciales, temporales, viales y meteorológicas disponibles no permiten predecir esta categoría con un desempeño aceptable, especialmente por la baja recuperación de OTROS. La exclusión del modelo responde a los resultados obtenidos y evita trasladar al prototipo una predicción que no cuenta con suficiente respaldo.

Una vez finalizadas la preparación de los datos y la evaluación de los modelos, el proyecto continúa con la implementación del prototipo. La semana 6 se destina a completar la interfaz e integrar el modelo de ocurrencia con el backend. Durante la semana 7 se implementará la solución en Streamlit y se ejecutarán las pruebas definidas en la matriz de requerimientos. Finalmente, la semana 8 se dedicará a la grabación del video y a la preparación de la entrega final.

13. Referencias

Google. (s. f.). *Routes API: Compute routes*. Google for Developers.

https://developers.google.com/maps/documentation/routes/compute_route_directions

Open-Meteo. (s. f.-a). *Historical Weather API*. <https://open-meteo.com/en/docs/historical-weather-api>

Open-Meteo. (s. f.-b). *Weather Forecast API*. <https://open-meteo.com/en/docs>

Peffer, K., Tuunanen, T., Rothenberger, M. A., & Chatterjee, S. (2007). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3), 45-77. <https://doi.org/10.2753/MIS0742-1222240302>

Secretaría Distrital de Movilidad. (s. f.). *Portal de Datos Abiertos de Movilidad de Bogotá*.

<https://datos.movilidadbogota.gov.co/>

Secretaría Distrital de Planeación. (s. f.). *Perímetro urbano. POT Bogotá D. C.* Datos Abiertos Bogotá.

<https://datosabiertos.bogota.gov.co/dataset/perimetro-urbano-bogota-d-c>